PROYECTO FINAL · CIENCIA DE DATOS · ENERGIA DIGITAL 2026

La defensa en cinco minutos

Guion repartido entre tres y las preguntas que conviene tener contestadas

---

Diseño de completación y productividad de pozos no convencionales en Vaca Muerta

Carolina Bailón · Martín Gerbaldo · Franco Malacalza

Trece diapositivas · 647 palabras de guion · entre 4:20 y 5:00 minutos

Acompaña a **Presentacion 5 minutos - Vaca Muerta.pdf**, que sigue el orden del modelo de la cátedra: objetivo, hipótesis, metodología, limpieza, clustering, modelo predictivo, predicción contra real, conclusiones y propuesta. Acá está, para cada diapositiva, quién habla, cuánto tiene, qué decir y qué pregunta invita; después, veinte preguntas previsibles con la respuesta corta primero.

1. Cómo queda repartido

Cinco minutos entre tres son unos cien segundos cada uno. El guion está escrito a esa medida: **647 palabras**, que a ritmo de presentación —entre 130 y 150 por minuto— dan entre 4:20 y 5:00. El margen que sobra es para las pausas y los dos cambios de orador.

Quién	Diapositivas	Palabras	Qué le toca
Carolina	1 Portada · 2 Contenido · 3 Objetivo 4 Hipótesis · 5 Metodología y datos	209 (32%)	Abre, plantea el problema, la hipótesis y los datos
Martín	6 Limpieza · 7 Cómo validamos 8 K-Means · 9 Random Forest	225 (35%)	Todo el trabajo de modelado
Franco	10 Predicción vs real · 11 Conclusiones 12 Propuesta · 13 Gracias	213 (33%)	Resultados, cierre y propuesta

Los dos cambios de orador son el riesgo del formato. Con cien segundos cada uno no hay lugar para un «bueno, ahora sigue...». Funciona cortar en seco y que el que sigue arranque con la primera frase de su diapositiva, que ya está escrita. Ensayar **sólo los dos cambios** tres veces alcanza.

2. Correspondencia con el modelo de la cátedra

El modelo de presentación que circuló tiene once secciones. Están todas cubiertas; las que en nuestro proyecto se resuelven distinto se indican en la tercera columna.

Sección del modelo	Nuestra diapositiva	Observación
Introducción / problema	3 · Objetivo del proyecto	Van juntas, por el tiempo
1. Objetivo del proyecto	3 · Objetivo del proyecto	—
2. Hipótesis	4 · Hipótesis	—
3. Metodología / datasets	5 · Metodología y datos	Los tres archivos, nombrados
4. Limpieza y preparación	6 · Limpieza y preparación	—
5. Preparación / división	7 · Cómo validamos	**Partición temporal, no 80/20 al azar**
6. Agrupamiento con K-Means	8 · Agrupamiento con K-Means	Cuatro familias de diseño
7. Silhouette score	8 · Agrupamiento con K-Means	Va en la misma: silueta 0,40
8. Modelo predictivo Random Forest	9 · Modelo predictivo	MAE, R^2 y referencia
9. Predicción vs dispersión real	10 · Predicción contra real	Sobre pozos nunca vistos
10. Conclusiones	11 · Conclusiones	—
11. Propuesta o solución	12 · Propuesta	La API desplegada

Dos diferencias deliberadas con el modelo, y conviene poder explicarlas.

La división de los datos. El modelo usa 80/20 al azar; nosotros usamos partición temporal. No es un descuido: es el hallazgo central del trabajo, y la diapositiva 7 lo explica. Si alguien pregunta por qué no hicimos 80/20, la respuesta está en la sección 4.

El logo. El modelo lleva el logo de la Fundación YPF en cada lámina. El nuestro usa la paleta pero no el logo, porque no teníamos el archivo. **Si la cátedra lo pide, agregarlo desde la plantilla antes de presentar**: en el PowerPoint se pega en la esquina superior derecha de cada diapositiva.

3. El guion, diapositiva por diapositiva

1 · PORTADA — Carolina — 10 s

> *Somos Carolina, Martín y Franco. Estudiamos cuánto de la producción de un pozo de Vaca Muerta se explica por cómo se lo diseñó.*

No leer la diapositiva ni anticipar la estructura: para eso está la siguiente.

2 · CONTENIDO — Carolina — 8 s

> *Éste es el recorrido: el problema, los datos, cómo validamos, los dos modelos y la propuesta.*

Ocho segundos, sin leer las diez líneas. Está para que el jurado sepa adónde va la charla.

3 · OBJETIVO DEL PROYECTO — Carolina — 35 s

El arco: la roca no entrega sola → eso es el diseño de completación → se decide antes y no tiene vuelta atrás → los cuatro objetivos → la pregunta.

> *…concentra buena parte del costo y se define antes de saber cuánto va a producir.*

Invita a: «¿por qué no miran también la geología?»

4 · HIPÓTESIS — Carolina — 25 s

Lo importante es que la hipótesis sea refutable, y acá lo es: si el modelo no le gana a predecir siempre la producción típica, el diseño no explica nada.

> *…suficiente para ordenar decisiones e insuficiente para dictaminar sobre un pozo.*

Invita a: «¿y se confirmó?» — sí, y está en la 11.

5 · METODOLOGÍA Y DATOS — Carolina — 25 s

Nombrar los tres archivos y de dónde salen. La cátedra lo pide explícitamente.

> *…mil novecientos diecisiete pozos de petróleo con doce meses completos medidos, que es lo que el modelo estima.*

Invita a: «¿por qué sólo 1.917?» y «¿por qué doce meses?»

6 · LIMPIEZA Y PREPARACIÓN — Martín — 23 s

Tres cosas y nada más: los ceros centinela, las cinco variables de intensidad, y qué dejamos afuera. La frase del Pipeline es la que muestra oficio.

> *Había ceros que marcaban «no informado»: los tratamos como faltantes y los completamos con la mediana de su formación geológica.*

Invita a: «¿por qué la mediana de la formación y no la global?»

7 · CÓMO VALIDAMOS — Martín — 35 s

Es la diapositiva más importante de las trece. Dos números, y por qué nos quedamos con el peor. Decirlos despacio y dejar un segundo de silencio al final.

> *Mismo modelo, mismos datos: cambia la pregunta. Como en el uso real se le van a pedir pozos nuevos, el número honesto es el peor.*

No decir «el modelo mejoró» ni «empeoró». El modelo es el mismo; cambió la medición. Confundir eso desarma el argumento, y es lo que el jurado va a estar escuchando.

Invita a: «un R^2 de 0,26 es bajísimo», «¿por qué no 80/20 como todos?» — las dos más probables de la defensa.

8 · AGRUPAMIENTO CON K-MEANS — Martín — 22 s

Nombrar las cuatro familias sin describirlas una por una —están en pantalla— y cerrar con lo que sorprende.

> *…el algoritmo reconstruyó la cronología de la cuenca sin haber visto una sola fecha.*

Invita a: «¿cómo eligieron k = 4?» y «una silueta de 0,40 es baja».

9 · MODELO PREDICTIVO — Martín — 30 s

El arco: qué modelo y por qué → las tres métricas → qué variables pesan → la advertencia de la operadora, que no es opcional.

> *…la arena importada es la menos importante. Y cuidado con la operadora: mide el área en concesión, no la habilidad.*

Invita a: «¿por qué no una red neuronal?», «¿optimizaron hiperparámetros?», «¿qué operadora es mejor?»

10 · PREDICCIÓN CONTRA REAL — Franco — 32 s

Explicar el gráfico antes de interpretarlo: cada punto es un pozo, el eje horizontal lo que produjo, el vertical lo que el modelo estimó, la línea punteada sería la predicción perfecta. Recién después, la lectura.

> *La nube se achata: a los que produjeron cincuenta y siete mil les estima cuarenta y nueve mil, y a los que produjeron quince mil les estima veintiséis mil.*

Decir esto es lo que distingue el trabajo. Mostrar un gráfico de predicción contra real y señalar vos mismo dónde el modelo falla vale más que cualquier métrica.

Invita a: «¿por qué comprime?» y «¿entonces para qué sirve?»

11 · CONCLUSIONES — Franco — 33 s

Tres conclusiones: la hipótesis se confirma, la tabla de las tres decisiones, y el techo. La tabla es el corazón de la defensa.

> *En tres momentos elegimos el resultado peor porque era el correcto, porque el número bueno venía de una validación que no respondía la pregunta real.*

Invita a: «¿qué es eso del año de fractura?» y «¿por qué acotaron los extremos?»

12 · PROPUESTA — Franco — 28 s

Es la sección que la cátedra pide como cierre: qué proponemos hacer con esto.

> *...avisa dónde se queda sin datos: si se le piden ocho mil metros responde, pero advierte que el más largo que vio mide cuatro mil novecientos sesenta y cinco.*

En cinco minutos, no abrir el navegador. Un arranque en frío de Render tarda hasta un minuto: el 20% del tiempo total mirando una pantalla en blanco. Los números están en la diapositiva. Si lo piden, se muestra después, en las preguntas, con el servicio ya despierto. Aun así, **abrir las dos pestañas diez minutos antes**.

13 · MUCHAS GRACIAS — Franco — 5 s

> *Muchas gracias. El repositorio y el servicio están en pantalla. Quedamos a disposición.*

Y punto. No agregar nada más: el silencio después del cierre es parte del cierre.

4. Las preguntas, con la respuesta corta primero

Sobre la validación — las más probables

"Un R^2 de 0,26 es muy bajo. ¿Sirve de algo?"

> **Corta:** Le gana por un 25% a la referencia, y lo que falta no es ajuste: es la geología, que no está en los datos abiertos.

La referencia honesta es predecir siempre la producción típica, y eso da un error absoluto medio de 14.138 m^3. Nuestro modelo da 10.596: un 25% menos. Probamos 180 combinaciones de hiperparámetros y el R^2 no se movió, así que el cuello de botella no es la búsqueda. Un modelo que sólo ve el diseño no puede explicar la roca, y la roca es lo que más manda en un no convencional.

"¿Por qué no dividieron 80/20 al azar, como se hace siempre?"

> **Corta:** Porque al azar el modelo entrena con pozos de 2024 y se lo evalúa con vecinos suyos. En el uso real eso nunca pasa.

Lo hicimos de las dos formas y las comparamos: al azar da 0,52 y por tiempo 0,26. Partir al azar deja que el modelo vea pozos del mismo año y la misma zona en los dos lados, que comparten geología y época. Como al modelo se le van a pedir pozos nuevos, de años que no vio, el 0,26 es lo que de verdad rinde. Informar el 0,52 sería prometer una precisión que no tiene.

"¿Y 10.596 m^3 de error es mucho o poco?"

> **Corta:** Es un 30% de la producción típica de los pozos con los que lo evaluamos.

La mediana del conjunto de evaluación es 35.681 m^3 a doce meses. Es mucho para comprometer una inversión sobre un pozo puntual, y es poco para ordenar diez diseños entre sí, que es el uso que proponemos.

"¿Cómo saben que no hay sobreajuste?"

> **Corta:** Porque lo medimos sobre años que el modelo nunca vio, y el bosque está regularizado.

La partición temporal es la prueba más dura posible: entrena con 1.298 pozos de hasta 2023 y se evalúa una sola vez sobre 619 de 2024-2025. Además el bosque lleva un mínimo de ocho muestras por hoja, que le impide memorizar pozos sueltos. Miramos la diferencia entre entrenamiento y evaluación en cada modelo que probamos.

Sobre el gráfico de predicción contra real

"¿Por qué la nube se achata hacia el centro?"

> **Corta:** Porque un bosque promedia. La hoja de cada árbol guarda el promedio de los pozos que cayeron ahí, y promediar comprime los extremos.

Es una propiedad del método, no un error de implementación. Para que el modelo prediga un pozo excepcional tendría que haber visto muchos pozos excepcionales con ese mismo diseño, y lo que distingue a esos pozos no está en el diseño: está en la roca. Por eso decimos que sirve para el grueso y no para los extremos.

“¿Entonces para qué sirve, si falla justo donde importa?”

> **Corta:** Para comparar, no para dictaminar.

La pregunta «¿cuál de estos dos diseños promete más?» la responde bien, porque sólo necesita el orden. La pregunta «¿cuánto va a dar este pozo?» no la responde con la precisión que haría falta para decidir una inversión. Las dos son preguntas legítimas y el modelo contesta una sola; decir cuál es parte del resultado.

Sobre los datos y la limpieza

“¿Por qué sólo 1.917 pozos si Vaca Muerta tiene muchos más?”

> **Corta:** Porque exigimos doce meses completos de producción medida.

Partimos de los pozos horizontales con rama de 500 metros o más. Se cae todo pozo que todavía no cumplió doce meses produciendo —no se puede medir lo que aún no pasó— y los que tienen el gas como objetivo. El clustering, que no necesita la variable objetivo, trabaja con 2.603: seiscientos ochenta y seis más, justamente porque no hace falta esperar.

“¿Por qué imputaron con la mediana de la formación y no con la global?”

> **Corta:** Porque la presión y la potencia dependen de la roca, y la formación es la mejor aproximación que teníamos.

Usar la mediana global habría metido en una formación valores típicos de otra. Imputar por grupo conserva esa estructura. Son además pocos casos: lo relevante fue darse cuenta de que los ceros no eran ceros reales sino marcadores de «no informado».

“¿Por qué doce meses y no la producción total del pozo?”

> **Corta:** Porque es la ventana que permite comparar pozos de distintos años entre sí.

Un pozo de 2019 lleva años produciendo y uno de 2024 recién arranca: sumar todo compararía edades, no diseños. Además los primeros doce meses son donde más pesa la completación, antes de que la declinación natural domine.

Sobre el clustering

“¿Cómo eligieron cuatro grupos?”

> **Corta:** Con tres criterios a la vez: codo, silueta y Calinski-Harabasz.

Ninguno de los tres decide solo. El codo sugería entre tres y cinco; la silueta y Calinski-Harabasz coincidían en que cuatro separaba mejor sin fragmentar. Y el criterio final fue que los cuatro grupos tuvieran una lectura física: convencional, intensivo, arena importada y alto volumen. Un agrupamiento que no se puede nombrar no sirve.

“Una silueta de 0,40 es baja. ¿No conviene otro k?”

> **Corta:** Sin acotar los extremos la silueta daba 0,62, y la bajamos a propósito.

Ese 0,62 premiaba un agrupamiento que aislaba tres pozos en un grupo propio: la métrica mejoraba describiendo tres casos en lugar de la cuenca. Acotando los extremos al 1% y al 99% la silueta cae a 0,40 y los grupos pasan a describir tipos de diseño reales. Es el mismo criterio que con el R^2: preferimos el número peor cuando el mejor responde otra pregunta.

"¿Probaron otros algoritmos de agrupamiento?"

> **Corta:** Sí: DBSCAN, Ward y mezcla de gaussianas. K-Means dio los grupos más interpretables.

También aplicamos reducción de dimensionalidad por SVD: las familias sobreviven con tres de las cinco dimensiones —índice de Rand ajustado 0,958— y se rompen con dos (0,374). La dimensión que se pierde en ese paso es casi exclusivamente la arena importada, que aporta apenas el 17% de la información. Si hubiéramos descartado dimensiones por su peso habríamos borrado el grupo más distintivo.

Sobre el modelo

"¿Por qué un Random Forest y no una red neuronal?"

> **Corta:** Son datos tabulares y 1.917 filas. Con ese tamaño una red no tiene ventaja y sí más formas de salir mal.

Comparamos contra una regresión lineal y contra un árbol solo; el bosque gana a los dos. Las redes rinden sobre texto, imágenes o series largas, no sobre una tabla de dos mil filas y diez columnas. Además el bosque nos da la importancia de cada variable y el desacuerdo entre sus árboles, de donde sale el rango que devuelve la API.

"¿Optimizaron hiperparámetros? ¿Con Optuna?"

> **Corta:** Con `RandomizedSearchCV`, 180 combinaciones, y validación cruzada temporal. El R^2 no se movió.

El resultado fue informativo justamente porque no mejoró: si 180 combinaciones no mueven la métrica, el problema no está en el modelo sino en la información disponible. Los valores finales son 600 árboles, mínimo 8 muestras por hoja y 40% de las variables por división.

"¿Qué es eso del año de fractura que sacaron?"

> **Corta:** Con el año el R^2 sube de 0,263 a 0,285, pero la mejora cambiaba de signo según dónde cortábamos.

Una variable que ayuda o perjudica según el corte no aporta señal estable: está aprendiendo la tendencia temporal de la cuenca, que no es lo que queremos que el modelo capture. Preferimos el modelo peor y estable.

"Según el modelo, ¿qué operadora es mejor?"

> **Corta:** El modelo no puede responder eso, y es importante que no se lo use así.

La variable operadora pesa tanto como la mejor variable de diseño, pero captura **la calidad del área que cada empresa tiene en concesión**, no su habilidad técnica. Una operadora con bloques en la zona más productiva va a tener mejores pozos aunque diseñe igual. Usarlo para rankear empresas sería un error de lectura, y lo dejamos escrito en el README.

“Entonces conviene hacer pozos más largos.”

> **Corta:** Dentro del rango que el modelo vio, y son asociaciones, no causas.

Sólo existen en los datos los pozos que efectivamente se perforaron, y los largos no se hicieron al azar: se hacen largos donde la geología acompaña, así que parte de lo que le atribuimos a la rama puede ser del lugar. Además el modelo deja de responder más allá de los 4.965 metros, y la API lo avisa. Y hay un límite económico que nuestros datos no tienen: no sabemos qué cuesta cada metro adicional.

Sobre la entrega y la puesta en producción

“¿Y la parte de clasificación?”

> **Corta:** La hicimos y está en el repositorio. El hallazgo fue que **cortar la predicción del regresor en el umbral funciona mejor que entrenar un clasificador**: AUC 0,791 contra 0,744.

Binarizar el objetivo tira información: para el clasificador, un pozo de 28.000 m³ y uno de 60.000 son «el mismo pozo». La vara tampoco es el 50% sino el 68,7% que se obtiene prediciendo «alto» siempre; el modelo le gana por seis puntos. Comete 112 falsos altos contra 43 falsos bajos, así que sirve para no perderse un pozo bueno, no para descartar.

“¿Cómo está desplegado? ¿Es reproducible?”

> **Corta:** FastAPI en un contenedor Docker, en Render, con el modelo versionado. Y `python src/entrenar.py` reconstruye todo desde cero.

La plataforma no entrena nada: el artefacto viaja en el repositorio y el servicio lo carga. Lo verificamos clonando el repositorio en un directorio vacío: el script rearma los 1.917 pozos y llega a MAE 10.596 y R^2 0,263, idénticos a los del notebook. Las semillas están fijadas y las versiones quedan escritas en `metadata.json`.

“¿Cómo evitan que el preprocesamiento de entrenamiento y el de producción se separen?”

> **Corta:** Están escritos una sola vez, en un módulo que importan los dos.

Las cinco fórmulas de intensidad viven en `src/caracteristicas.py` y lo importan tanto el entrenamiento como la API. El resto viaja dentro del mismo `Pipeline` que se serializa. Si estuvieran escritas dos veces, el día que alguien corrigiera una la otra quedaría vieja y el error sería silencioso.

5. Cinco frases que conviene no decir

No decir	Por qué, y qué decir en su lugar
«El modelo mejoró con la partición temporal»	El modelo es el mismo; cambió la medición. Decir: «lo medimos de forma más exigente».
«El modelo predice la producción de un pozo»	Invita a creerle sobre un pozo individual, que es lo que no hace. Decir «estima», y agregar el rango.
«La operadora X es la mejor»	Mide el área en concesión, no la habilidad.
«Alargar la rama aumenta la producción»	Es una asociación. Decir: «los pozos más largos, con la misma intensidad por metro, producen más».
«Con más datos el R^2 subiría»	No lo sabemos: más pozos del mismo tipo no agregan geología. Decir: «con datos de geología esperaríamos que suba».

6. Si algo falla

- **Se cae el proyector.** Las trece diapositivas se cuentan sin mirarlas: el guion está escrito como discurso. Seguir hablando.
- **Se van de tiempo.** Las sacrificables son la 2 (contenido) y la 6 (limpieza): se pasan en cinco segundos. **Las diapositivas 7, 10 y 11 no se tocan**, son el argumento.
- **Preguntan algo que no sabemos.** «No lo medimos» es mejor que improvisar. Se puede agregar qué haría falta para saberlo.
- **Piden ver la API.** Está en `entregafinal-data-science.onrender.com/demo`, con las pestañas ya abiertas. Mostrar el salto de 2.000 a 3.600 metros y el aviso de fuera de rango; nada más.

Un consejo sobre el tono. En cinco minutos no hay lugar para demostrar todo lo que se hizo, y el intento de meterlo se nota. Lo que sí entra es una idea defendida bien: que el número que vale es el que responde la pregunta real, aunque sea el peor. Si el jurado se lleva eso, se lleva lo mejor del trabajo.
