PROYECTO FINAL · CIENCIA DE DATOS · ENERGIA DIGITAL 2026

La defensa de la presentación

Las diecisiete diapositivas repartidas entre tres, y las preguntas que conviene tener contestadas

---

Diseño de completación y productividad de pozos no convencionales en Vaca Muerta

Carolina Bailón · Martín Gerbaldo · Franco Malacalza

Diecisiete diapositivas · entre 11 y 13 minutos de habla · la demostración aparte

Acompaña a **presentacion.pdf** y al **.pptx**, que lleva el nombre de quien habla al principio de cada nota del orador. Acá está, para cada diapositiva, cuánto dura, qué no conviene decir y qué pregunta invita; después, la demostración en vivo paso a paso y veinte preguntas previsibles con la respuesta corta primero.

1. Cómo queda repartido

La cátedra pide entre diez y quince minutos, que estén los tres y que hablen todos. El guion de las notas suma **1.689 palabras**: entre **11 y 13 minutos** a ritmo de presentación, más la demostración en vivo. Entra con margen.

Quién	Diapositivas	Tiempo	Qué le toca
Carolina	1 Portada · 2 El problema · 3 La pregunta 4 Los datos · 5 El EDA · 6 La variable objetivo	~3:20	Abre, instala el problema y explica con qué datos se trabaja
Martín	7 El método · 8 La regresión · 9 El hallazgo 10 Por qué · 11 Las variables · 12 La operadora	~3:30	El modelado y el hallazgo metodológico
Franco	13 Clasificación · 14 Las familias · 15 Validación 16 La demostración · 17 El cierre	~3:00 + demo	Las otras dos entregas, la demostración y el cierre

Los dos cambios de orador son lo único que hay que ensayar sí o sí. Pasan en la diapositiva 7 (Carolina → Martín) y en la 13 (Martín → Franco). Lo que funciona es cortar en seco y que el que sigue arranque con la primera frase de su diapositiva. Tres pasadas de esos dos momentos alcanzan; no hace falta ensayar las diecisiete.

2. El guion, diapositiva por diapositiva

Las notas completas están en el `.pptx`, en vista de moderador. Acá va lo que las notas no dicen: el tiempo de cada una, dónde hay que tener cuidado y qué pregunta invita.

Carolina · diapositivas 1 a 6

1 · Portada — 25 s

Presentarse los tres y decir el tema en una frase. Aclarar que son datos públicos y que el trabajo cubre cuatro entregas. **Sin números todavía.**

2 · El problema — 30 s

La esponja es la imagen que hace entender todo lo demás. Cerrar con que estas decisiones son plata, se toman a ciegas y no se deshacen: ésa es la razón de estudiarlas.

Invita a: «¿cuánto cuesta un pozo?» — no lo tenemos en los datos, y conviene decirlo así.

3 · La pregunta — 30 s

Leerla tal cual y hacer una pausa. La restricción importante es «sabiendo sólo cómo se lo diseñó»: el modelo no ve la geología.

Invita a: «¿y por qué no incluyeron la geología?» — porque no está en los datos abiertos, y es el techo del trabajo. Aparece de nuevo en la 17.

4 · Los datos y el alcance — 40 s

Cada corte del embudo está justificado: es acotar el alcance, no descartar datos. El dato que convence: un vertical bombea 0 toneladas de arena y 430 m³ de agua; un horizontal, 8.576 y 54.314.

Invita a: «¿por qué sólo 1.917 pozos?» — guardarse que el clustering recupera 2.603 porque no necesita la producción. Se dice en la 14.

5 · El análisis exploratorio — 35 s

El formato de la cursada pide explícitamente «qué descubrimos explorando». Las dos de arriba van juntas: el diseño cambió muchísimo, pero no en todas las dimensiones.

6 · La variable objetivo — 40 s

Responde «cuál es la variable a predecir», que el formato también pide. Lo que hay que transmitir: **la variable no estaba en los datos, la construimos**, y construirla bien fue la mitad del trabajo.

Invita a: «¿probaron transformar la variable?» — sí: la asimetría original era 0,57 y `log1p` la llevaba a −2,44, así que lo descartamos con la medición a la vista.

Martín · diapositivas 7 a 12

7 · El método — 25 s

Es el mapa de la charla. Mencionar que cada caja es un notebook del repositorio y que están todos ejecutados. La distinción supervisado / no supervisado se dice acá **una sola vez**.

8 · La regresión — 45 s

Dos cosas: el error está en metros cúbicos, la misma unidad que la producción —unos 10.600 sobre una producción típica de 36.000—, y que los modelos lineales y los de árboles queden casi empatados **es informativo**: la señal es sencilla.

Invita a: «¿por qué no una red neuronal?» — respuesta en la sección 4.

9 · El hallazgo

30 s

Es el momento fuerte de la presentación. Bajar el ritmo. Decir los dos números, pausa, y recién después explicar. Que el público se quede un segundo con la incomodidad de que el mismo modelo dé 0,52 y 0,26.

No decir «el modelo mejoró» ni «empeoró»: el modelo es el mismo, cambió la medición. Es el error que más desarma el argumento.

10 · Por qué pasa

35 s

La analogía del examen es lo único que hay que decir bien; el resto se sigue solo. La columna derecha prueba que no es un artefacto del conjunto de prueba.

11 · Qué variables pesan

45 s

Un desvío estándar de rama son unos 900 metros: «cada 900 metros más de rama, unos 7.400 m³ más de petróleo en el primer año». La primera barra es casi el triple de la segunda.

Invita a: «¿y la presión máxima?» — la sacamos porque los dos modelos no coinciden sobre ella y es la variable con más valores imputados.

12 · La lectura no técnica

25 s

Si el público sólo se lleva una diapositiva, que sea ésta. **Las cuatro advertencias conviene decirlas nosotros**, sin esperar la pregunta: queda mucho mejor que si las tiene que señalar el que escucha.

Invita a: «¿qué operadora es mejor?» — la trampa clásica. Respuesta en la sección 4.

Franco · diapositivas 13 a 17

13 · La clasificación

35 s

Noventa segundos y se pasa. La moraleja es general: cuando la categoría se construye cortando algo que se puede medir, conviene modelar la cosa medible y cortar después. La diferencia de 0,047 en AUC es veinte veces la que separa a los dos clasificadores, así que no es ruido.

14 · Las familias de diseño

40 s

La analogía de las mil fotos sin etiquetar explica qué es no supervisado. El remate: **el algoritmo no vio el año** y reconstruyó la cronología igual.

Invita a: «¿por qué cuatro grupos?» — los índices no coinciden, dos votan 2 y uno vota 6; elegimos 4 por estabilidad, tamaño e interpretabilidad.

15 · La validación del clustering

40 s

Una frase para llevarse: **una variable puede ser irrelevante para predecir y central para describir**. Decir la advertencia de causalidad sin que la pregunten: entre 2015 y 2024 no cambió sólo el diseño, cambió también dónde se perfora.

16 · La demostración en vivo

~2 min

Hablar poco y mostrar. Tiene su propia sección más abajo, porque es lo único que puede salir mal por causas ajenas.

17 · El cierre

40 s

Cerrar por la tabla del medio, que es el corazón de la defensa: **tres veces elegimos el número peor porque era el correcto**. Decirlo sin adornos y quedarse callado un segundo. Después «gracias» y punto.

Invita a: «un 26% es poquísimo» — la más probable de toda la defensa. Primera de la sección 4.

3. La demostración en vivo

Con quince minutos la demostración entra, y conviene hacerla: es lo que distingue este trabajo de un cuaderno. Pero es también lo único que depende de algo que no controlamos.

> **Diez minutos antes de entrar al aula**, abrir las dos direcciones en sendas pestañas y dejarlas cargadas. La capa gratuita de Render duerme el servicio tras quince minutos sin uso y la primera petición puede tardar casi un minuto. En vivo eso se ve como si nada funcionara.

El guion, en orden

1. **Empezar por el panel**, en `/demo`: tiene tres botones de pozo de ejemplo y deslizadores, así que el número cambia delante de todos sin pegar nada.
2. **Apretar «Pozo corto» y «Pozo largo»:** 29.224 m³ y 49.903 m³. Mismo diseño por metro, setenta por ciento más de petróleo.
3. **Arrastrar la rama más allá de los 4.965 metros:** la curva se aplana y entra en la franja marcada. Ése es el límite del modelo hecho dibujo, y es el mejor momento de la demostración. La frase: *«el pozo más largo que vio el modelo mide 4.965 metros; de ahí en más devuelve siempre lo mismo, porque un bosque no extrapola»*.
4. **Si preguntan por la implementación**, recién ahí `/docs`: desplegar `POST /predict`, «Try it out», ejecutar, y señalar tres cosas de la respuesta —el número, el rango y las variables de intensidad, que prueban que el servicio hace el mismo feature engineering que el entrenamiento—.

> **Dos reglas que evitan el papelón.**
>
> **No editar un solo campo a mano en `/docs`:** los pozos se pegan enteros desde el guion impreso. Alargar la rama sin subir la arena y el agua *baja* la estimación, porque lo que el modelo aprendió es la intensidad por metro, no el largo.
>
> **No improvisar con otros campos.** Si la conexión falla, los números de la franja de abajo de la diapositiva son los reales: la diapositiva sostiene sola el argumento y se sigue sin pedir disculpas.

4. Las preguntas, con la respuesta corta primero

Sobre el resultado

"Un R^2 de 0,26 es muy bajo. ¿Sirve de algo?"

> **Corta:** Le gana por un 25% a la referencia, y lo que falta no es ajuste: es la geología, que no está en los datos abiertos.

La referencia honesta es predecir siempre la producción típica, y eso da un error absoluto medio de 14.138 m^3. Nuestro modelo da 10.596: un 25% menos. Probamos 180 combinaciones de hiperparámetros y el R^2 no se movió, así que el cuello de botella no es la búsqueda. Un modelo que sólo ve el diseño no puede explicar la roca.

"¿Y 10.596 m^3 de error es mucho o poco?"

> **Corta:** Es un 30% de la producción típica de los pozos con los que lo evaluamos.

La mediana del conjunto de evaluación es 35.681 m^3 a doce meses. Es mucho para comprometer una inversión sobre un pozo puntual y poco para ordenar diez diseños entre sí, que es el uso que proponemos.

"¿Por qué informan el peor número y no el mejor?"

> **Corta:** Porque el mejor responde una pregunta que nadie va a hacerle al modelo.

El 0,52 sale de partir los pozos al azar, lo que deja que el modelo entrene con pozos de 2024 y se lo evalúe con vecinos suyos, del mismo año y la misma zona. En el uso real se le van a pedir pozos nuevos. Informar el 0,52 sería prometer una precisión que no tiene.

Sobre el método

"¿Por qué un Random Forest y no una red neuronal?"

> **Corta:** Son datos tabulares y 1.917 filas. Con ese tamaño una red no tiene ventaja.

Comparamos contra una regresión lineal y contra un árbol solo. Que los lineales y los de árboles queden casi empatados dice que la señal es sencilla y que no hay nada que ganar con más complejidad. Además el bosque nos da la importancia de cada variable y el desacuerdo entre sus árboles, de donde sale el rango que devuelve la API.

"¿Optimizaron hiperparámetros? ¿Con Optuna?"

> **Corta:** Con `RandomizedSearchCV`, 180 combinaciones y validación cruzada temporal. El R^2 no se movió.

El resultado fue informativo justamente porque no mejoró: si 180 combinaciones no mueven la métrica, el problema no está en el modelo sino en la información disponible. Los valores finales son 600 árboles, mínimo 8 muestras por hoja y 40% de las variables por división.

"¿Cómo saben que no hay sobreajuste?"

> **Corta:** Porque lo medimos sobre años que el modelo nunca vio, y el bosque está regularizado.

Entrena con 1.298 pozos de hasta 2023 y se evalúa una sola vez sobre 619 de 2024-2025. El mínimo de ocho muestras por hoja le impide memorizar pozos sueltos. Miramos la diferencia entre entrenamiento y evaluación en cada modelo que probamos.

"¿Por qué sacaron el año de fractura, si con él da mejor?"

> **Corta:** Porque la mejora cambiaba de signo según dónde cortábamos.

Con el año el R^2 sube de 0,263 a 0,285, pero al mover el año de corte la ventaja desaparecía y se daba vuelta. Una variable que ayuda o perjudica según el corte está aprendiendo la tendencia temporal de la cuenca, no señal estable. Preferimos el modelo peor y estable.

"¿Y los valores extremos? ¿No habría que sacarlos?"

> **Corta:** En el clustering los acotamos al 1% y al 99%, y la métrica bajó a propósito.

Sin acotar, la silueta daba 0,62; acotando, 0,40. Ese 0,62 premiaba un agrupamiento que aislaba tres pozos en un grupo propio. La métrica mejor estaba midiendo algo que no servía. En regresión no los sacamos: los pozos excepcionales son parte del fenómeno.

Sobre los datos

"¿Por qué sólo 1.917 pozos si Vaca Muerta tiene muchos más?"

> **Corta:** Porque exigimos doce meses completos de producción medida.

Partimos de los horizontales con rama de 500 metros o más; se cae todo pozo que aún no cumplió doce meses produciendo y los que tienen el gas como objetivo. El clustering trabaja con 2.603 —686 más— porque no necesita la variable objetivo.

"¿Qué hicieron con los datos faltantes?"

> **Corta:** Imputamos por la mediana de la formación productiva, no por la global.

En presión, potencia y agua había ceros que marcaban «no informado», no ceros reales. Los tratamos como faltantes y los completamos con la mediana de su misma formación geológica, que es más informativa. Usar la global habría metido en una formación valores típicos de otra.

"¿Por qué doce meses y no la producción total?"

> **Corta:** Porque es la ventana que permite comparar pozos de distintos años entre sí.

Un pozo de 2019 lleva años produciendo y uno de 2024 recién arranca: sumar todo compararía edades, no diseños. Además los primeros doce meses son donde más pesa la completación.

Sobre la interpretación

“Entonces conviene hacer pozos más largos.”

> **Corta:** Dentro del rango que el modelo vio, y son asociaciones, no causas.

Sólo existen en los datos los pozos que efectivamente se perforaron, y los largos no se hicieron al azar: se hacen largos donde la geología acompaña, así que parte de lo que le atribuimos a la rama puede ser del lugar. Además el modelo deja de responder más allá de los 4.965 metros, y la API lo avisa. Y no sabemos qué cuesta cada metro adicional.

“Según el modelo, ¿qué operadora es mejor?”

> **Corta:** El modelo no puede responder eso, y es importante que no se lo use así.

La variable operadora pesa tanto como la mejor variable de diseño, pero captura **la calidad del área que cada empresa tiene en concesión**, no su habilidad técnica. Una operadora con bloques en la zona más productiva va a tener mejores pozos aunque diseñe igual. Lo dejamos escrito en el README.

“¿Esto le sirve a alguien en la práctica?”

> **Corta:** Para ordenar diseños y comparar carteras, sí. Para decidir sobre un pozo, no.

El error se triplica en los extremos, así que no anticipa ni el pozo excepcional ni el fracaso, que son los dos casos donde más dinero hay en juego. Donde sí rinde es en la comparación: cuál de dos diseños promete más, o si una cartera está por encima o por debajo de lo esperable.

“¿Por qué el modelo comprime hacia el centro?”

> **Corta:** Porque un bosque promedia, y promediar achata los extremos.

La hoja de cada árbol guarda el promedio de los pozos que cayeron ahí. Para que el modelo prediga un pozo excepcional tendría que haber visto muchos pozos excepcionales con ese mismo diseño, y lo que los distingue no está en el diseño: está en la roca.

Sobre las otras dos entregas

“¿Por qué cuatro grupos en el clustering?”

> **Corta:** Porque los índices no coinciden, y elegimos por estabilidad, tamaño e interpretabilidad.

Dos índices votaban 2 grupos y uno votaba 6. Ninguno decide solo. El criterio final fue que los cuatro grupos tuvieran una lectura física —convencional, intensivo, arena importada y alto volumen—: un agrupamiento que no se puede nombrar no sirve. Está argumentado en el notebook.

“¿Y la clasificación, para qué sirvió?”

> **Corta:** Para descubrir que **cortar la predicción del regresor en el umbral funciona mejor que entrenar un clasificador**: AUC 0,791 contra 0,744.

Binarizar el objetivo tira información: para el clasificador, un pozo de 28.000 m³ y uno de 60.000 son «el mismo pozo». La vara tampoco es el 50% sino el 68,7% que se obtiene prediciendo «alto» siempre; el modelo le gana por seis puntos. Comete 112 falsos altos contra 43 falsos bajos, así que sirve para no perderse un pozo bueno, no para descartar.

Sobre la puesta en producción

"¿Cómo está desplegado? ¿Es reproducible?"

> **Corta:** FastAPI en Docker, en Render, con el modelo versionado. Y `python src/entrenar.py` reconstruye todo desde cero.

La plataforma no entrena nada: el artefacto viaja en el repositorio. Lo verificamos clonando en un directorio vacío: el script rearma los 1.917 pozos y llega a MAE 10.596 y R^2 0,263, idénticos a los del notebook. Las semillas están fijadas y las versiones quedan escritas en `metadata.json`.

"¿Cómo evitan que el preprocesamiento de entrenamiento y el de producción se separen?"

> **Corta:** Están escritos una sola vez, en un módulo que importan los dos.

Las cinco fórmulas de intensidad viven en `src/caracteristicas.py` y lo importan tanto el entrenamiento como la API. El resto viaja dentro del mismo `Pipeline` que se serializa. Si estuvieran escritas dos veces, el día que alguien corrigiera una la otra quedaría vieja y el error sería silencioso.

5. Cinco frases que conviene no decir

No decir	Por qué, y qué decir en su lugar
«El modelo mejoró con la partición temporal»	El modelo es el mismo; cambió la medición. Decir: «lo medimos de forma más exigente».
«El modelo predice la producción de un pozo»	Invita a creerle sobre un pozo individual, que es lo que no hace. Decir «estima», y agregar el rango.
«La operadora X es la mejor»	Mide el área en concesión, no la habilidad.
«Alargar la rama aumenta la producción»	Es una asociación. Decir: «los pozos más largos, con la misma intensidad por metro, producen más».
«Con más datos el R^2 subiría»	No lo sabemos: más pozos del mismo tipo no agregan geología. Decir: «con datos de geología esperaríamos que suba».

6. Si algo falla

- **Se cae el proyector.** Las notas están escritas como discurso, no como pie de figura. Se cuenta sin mirar.
- **Se van de tiempo.** Las sacrificables son la 5 (EDA) y la 13 (clasificación): se resumen en una frase cada una. **Las diapositivas 9, 16 y 17 no se tocan**, son el argumento.
- **No anda la demostración.** Los números de la diapositiva 16 son los reales. Se sigue sin pedir disculpas.
- **Preguntan algo que no sabemos.** «No lo medimos» es mejor que improvisar, y se puede agregar qué haría falta para saberlo.

Un consejo sobre el tono. El profesor ya dijo que están aprobados y que esto no es un examen, así que la presentación no tiene que demostrar nada: tiene que contar algo. Lo que mejor cuenta este trabajo no es el R^2, es que en tres lugares eligieron el número peor porque era el correcto. Si el aula se lleva eso, se lleva lo mejor.

Proyecto final de Ciencia de Datos · EnergIA Digital 2026 · Carolina Bailón, Martín Gerbaldo y Franco Malacalza · Repositorio: github.com/FrancoMalacalza01/entrega-final-data-science