Ciencia de Datos · EnergIA Digital 2026

Cómo explicar y defender el proyecto

Diseño de completación y productividad de pozos en Vaca Muerta

Una guía corta y sin jerga: qué decir, en qué orden, con qué números, y qué contestar si preguntan. Todo lo que está acá sale de los notebooks del repositorio.

Integrantes: Franco Malacalza · Martín Gerbaldo · Carolina Bailón

Repositorio: github.com/FrancoMalacalza01/entrega-final-data-science

Contenido: cuatro notebooks, una API y la presentación

1. El proyecto en treinta segundos

Antes de fracturar un pozo en Vaca Muerta, la operadora decide cuánto va a medir el tramo horizontal, en cuántas etapas lo va a fracturar y cuánta arena y agua va a bombear. Eso es el **diseño de completación**, se lleva la mayor parte del costo del pozo y es irreversible.

Nosotros tomamos los datos públicos de la Secretaría de Energía y nos preguntamos: **¿cuánto petróleo va a producir un pozo en su primer año, sabiendo sólo cómo se lo diseñó?**

La respuesta corta: el diseño explica una parte real pero minoritaria —un 26%— y lo que falta es la geología, que no está en datos abiertos. La decisión que más mueve la producción es **la longitud del tramo horizontal**. Y el hallazgo que más nos sorprendió no es sobre pozos sino sobre método: **si hubiéramos evaluado el modelo como se hace por costumbre, habríamos informado el doble de precisión de la que realmente tiene**.

2. De qué se trata, en criollo

En Vaca Muerta el petróleo no está en una bolsa subterránea de la que se pueda bombear. Está **atrapado dentro de la roca**, como el agua en una esponja muy apretada. Para sacarlo hay que romper la roca:

1. Se perfora para abajo y después **se dobla y se sigue de costado** varios kilómetros. Ese tramo acostado es la **rama horizontal**.
2. Se divide la rama en **etapas** —decenas— y en cada una se bombea agua con arena a muchísima presión, para agrietar la roca.
3. La **arena** queda trabando las grietas para que no se cierren. Por esas grietas sale el petróleo.

Cada una de esas decisiones es plata: más metros de rama, más etapas y más arena cuestan más. Y una vez bombeada, la arena no se recupera. Por eso vale la pena preguntarse cuáles de esas decisiones realmente se pagan en producción.

3. Los datos: de dónde salen y cuántos son

Son dos archivos públicos de la Secretaría de Energía de la Nación, que cruzamos por el número de pozo. Uno trae el **diseño** (lo que la operadora decidió) y el otro la **producción** (lo que el pozo después dio, mes por mes).

Paso	Pozos	Por qué
Registros de fractura publicados	4.890 filas	el archivo crudo; algunas operaciones vienen cargadas en varias filas
Pozos distintos	4.646	consolidamos las cargas partidas sumándolas
Pozos horizontales (nuestro alcance)	2.603	el 42% eran verticales: otra tecnología, otra escala, no se mezclan
Con un año completo de producción	2.108	sin 12 meses medidos no hay nada que predecir
Pozos de petróleo usados para modelar	**1.917**	**sacamos 191 pozos cuyo objetivo es el gas: es otro problema**

De esos 1.917 pozos, los **1.298 fracturados hasta 2023** son los que el modelo usa para aprender y los **619 de 2024 y 2025** quedan apartados para la prueba final. En la sección 7 está la razón, que es el corazón del trabajo.

4. Qué es un “modelo” (sin jerga)

La analogía que conviene usar. Pensá en alguien que tasa autos usados. Le mostrás mil autos con su marca, kilometraje y año, y *con el precio al que se vendieron*. De tanto mirarlos, aprende a estimar el precio de un auto que todavía no vio. Eso es un **modelo supervisado**: aprende de ejemplos que ya tienen la respuesta.

Nuestro tasador no mira autos: mira pozos. Las características son el diseño —metros de rama, etapas, arena, agua— y el “precio” es cuántos metros cúbicos de petróleo produjo el pozo en sus primeros doce meses.

Dos ideas más y ya está todo el vocabulario que hace falta:

- **Hay que tener contra qué comparar.** Antes de festejar un modelo, hay que ver si le gana a algo tonto. Nuestro “algo tonto” es predecir siempre el valor típico, sin mirar nada del pozo: como un loro que repite el mismo número. Se le dice **modelo de referencia**, y si el modelo no le gana, no sirve.
- **No se puede estudiar con el examen resuelto.** Si evaluamos al modelo con los mismos pozos con los que aprendió, va a parecer brillante aunque sólo esté repitiendo de memoria. Por eso se aparta un grupo de pozos, no se los toca en todo el proceso, y se los usa **una sola vez** al final. Cuando un modelo anda bien en lo que estudió y mal en lo nuevo, se dice que está **sobreajustado**.

5. Qué hicimos, en cinco pasos

Paso	Qué hicimos
1. Limpiar	El problema no eran los datos faltantes sino los **valores imposibles**: presiones en cero, pozos con 3 metros de rama (un relleno repetido 63 veces). Los detectamos y los corregimos.
2. Construir variables útiles	Las variables crudas no se pueden comparar entre pozos: un pozo más largo lleva más arena porque es más largo, no porque se lo haya fracturado más fuerte. Creamos **variables de intensidad** —arena por metro, agua por metro, metros entre etapas— que sí se comparan.
3. Armar la variable a predecir	Sumamos la producción de petróleo de los primeros 12 meses de cada pozo, cuidando no contar pozos que todavía no cumplieron el año.
4. Entrenar y comparar	Cuatro modelos de dos familias distintas (lineales y de árboles), más el de referencia. Después validación cruzada y búsqueda de los mejores ajustes: **120 combinaciones** probadas con `GridSearchCV` y 60 al azar con `RandomizedSearchCV`.
5. Mirar dónde se equivoca	No sólo cuánto se equivoca: **dónde**. Y plantear la misma pregunta como clasificación ("¿va a ser un pozo bueno?") para comparar los dos enfoques.

6. Los números que conviene saber de memoria

Qué	Cuánto	Cómo se dice
Error del loro (referencia)	14.138 m³	"lo que erra predecir siempre el valor típico"
Error de nuestro modelo	**10.596 m³**	**"un 25% menos de error que la referencia"**
R^2 en la prueba	0,263	"explica el 26% de la variabilidad"
R^2 si partiéramos al azar	0,52	"el doble, y es un espejismo"
Efecto de la rama horizontal	+7.382 m³	"por cada ~900 m más de rama"
Efecto de la arena importada	+79 m³	"indistinguible de cero"
Aciertos del clasificador	75,0%	"contra 68,7% de la referencia"
Pozos para aprender / para probar	1.298 / 619	"hasta 2023 / 2024 y 2025"
Familias de diseño encontradas	4	"y el algoritmo no vio el año"
Producción típica: mejor y peor familia	36.760 / 3.311 m³	"un factor de once"
Pozos que usa el clustering	2.603	"686 más, porque no necesita el objetivo"
Dimensiones para que sobrevivan las familias	3 de 5	"con dos se rompe el agrupamiento"
La API, sobre el pozo de ejemplo	38.506 m³	"y devuelve además un rango"

El R^2 va de 0 a 1 y dice qué parte de las diferencias entre pozos queda explicada. El error está en metros cúbicos, la misma unidad que la producción, así que se lee directo: el modelo le pega con un margen de unos 10.600 m^3 sobre una producción típica de unos 36.000.

7. El hallazgo principal, bien simple

Hay dos formas de elegir qué pozos usar para probar el modelo:

- **Al azar:** se sortean los pozos, sin mirar la fecha. Es lo que se hace por costumbre.
- **Por tiempo:** el modelo aprende con los pozos viejos y se lo prueba con los nuevos. Es lo que hicimos.

El mismo modelo, con las mismas variables, da **R^2 0,52 con la partición al azar y 0,26 con la temporal**. Exactamente el doble, y el factor se repite en los tres modelos que probamos.

> **Por qué pasa.** El diseño de los pozos cambia año a año: los de 2024 son mucho más largos que los de 2018. Si sorteamos al azar, el modelo estudia con pozos de 2024 y después lo evaluamos con *otros* pozos de 2024: ya conoce la receta del año. Es como rendir un examen habiendo visto las preguntas de ese mismo examen. Rinde bien, pero no demuestra nada.
>
> Con la partición temporal le pedimos lo que de verdad le vamos a pedir en la práctica: **estimar los pozos del año que viene, que todavía no existen**.

Y lo confirmamos por un segundo camino que ni siquiera toca los pozos de prueba, sólo los de aprendizaje: la validación cruzada repartida al azar da R^2 0,546 y la repartida por tiempo, 0,171. La forma de validar infla el resultado 3,2 veces.

> **La frase para decir en la defensa:** "la métrica no mide solamente al modelo: mide también al esquema de validación. Nosotros preferimos informar 0,26 que se sostiene, antes que 0,52 que se cae el día que el modelo se usa con pozos nuevos."

8. Qué cambiaría una operadora

Ésta es la traducción del modelo a decisiones concretas. Es la parte que le interesa a alguien que no es técnico.

Decisión	Qué dice el modelo
Alargar la rama horizontal	**Es la palanca grande, y por lejos: cada ~900 m más se asocian a +7.400 m³ en el primer año, casi el triple que la segunda variable. Es también el camino por el que la industria subió la productividad: la rama mediana se triplicó en diez años.**
Apretar las etapas	Fracturar más denso —menos metros entre etapas— suma, y aparece con el mismo signo en los dos tipos de modelo.
Más arena por metro	Efecto chico y con rendimientos decrecientes. Coincide con lo que vimos en la exploración: la arena por metro **dejó de crecer en 2019**, y el crecimiento posterior vino de pozos más largos, no más intensos.
Arena importada en vez de nacional	**No mueve la aguja:** +79 m³ en el modelo lineal e importancia exactamente 0,0000 en el de árboles. Es un resultado útil justamente por negativo: es una decisión de compra que cuesta y que, según estos datos, no se paga en producción.

Y lo que hay que decir en la misma frase que los resultados, sin esperar que lo pregunten:

- El modelo explica el 26%: sirve para **ordenar prioridades de diseño y comparar conjuntos de pozos**, no para dictaminar sobre un pozo puntual.
- Lo que no explica es **sobre todo la geología**, que no está en los datos abiertos. Dos pozos iguales en áreas distintas pueden producir muy distinto.
- El peso que el modelo le da a la operadora **no mide la habilidad de la empresa**: mide la calidad del área que le tocó.
- Son **asociaciones, no causas**. Sólo existen los pozos que se perforaron: no hay forma de saber qué habría producido uno de ellos con otro diseño.

9. La otra mitad: clasificar en vez de predecir el número

La misma pregunta se puede plantear de otra forma: en lugar de “cuántos metros cúbicos”, preguntar **“¿va a ser este pozo uno de los buenos?”**. Dos respuestas posibles, alto o bajo. El corte lo pusimos en el valor típico de los pozos de aprendizaje: 28.853 m³.

El clasificador acierta el **75,0%** contra el 68,7% de la referencia. Pero el resultado interesante es otro, y es el que conviene contar:

Camino	Aciertos	Capacidad de ordenar (AUC)
Entrenar un clasificador para la tarea	75,0%	0,744
Tomar el modelo que predice el número y comparar su predicción contra el corte	**76,3%**	**0,791**

El rodeo gana. La razón es simple: al partir en dos categorías se tira información. Para el clasificador, un pozo de 28.000 m³ y uno de 5.000 son los dos “bajo” y aprende lo mismo de ambos. El que predice el número sabe que uno estuvo al borde y el otro fue un fracaso, y ese orden más fino se conserva cuando después se lo corta.

La moraleja, que es general: cuando la categoría se construye cortando algo que se puede medir, conviene modelar la cosa medible y cortar después. Si las clases fueran de verdad categóricas —sano o enfermo— no habría ningún número que predecir y esto no aplicaría.

10. La cuarta pregunta: ¿existen tipos de diseño?

Las tres primeras partes tenían una respuesta conocida —cuánto produjo cada pozo— y entrenábamos modelos para predecirla. La cuarta da vuelta el planteo: **le sacamos la respuesta al algoritmo**. Le damos solamente la receta de fractura de cada pozo y le preguntamos si los pozos se parecen entre sí de alguna forma sistemática.

La analogía que conviene usar. Es la diferencia entre darle a alguien mil fotos de animales ya etiquetadas —"esto es un perro, esto es un gato"— y darle las mismas mil fotos sin ninguna etiqueta, pidiéndole que arme pilas con los que se parezcan. En el segundo caso nadie le dijo cuántas pilas hacer ni cómo se llama cada una. Eso es **aprendizaje no supervisado**, y es lo que hicimos acá.

Un detalle que suma y conviene mencionar: como esta pregunta no necesita saber cuánto produjo el pozo, pudimos usar **2.603 pozos en lugar de 1.917**. Son **686 pozos más**, los que todavía no cumplieron doce meses de producción y que las otras partes tenían que dejar afuera.

Lo que encontró

El algoritmo separó los pozos en **cuatro familias de diseño**, mirando nada más que cinco números por pozo: cuántos metros hay entre etapas, cuánta arena y cuánta agua por metro, la mezcla entre las dos, y qué proporción de la arena es importada.

Familia	Pozos	Cómo se reconoce	Año típico
Intensivo moderno	1.476	**Rama de 2.800 m, 48 etapas cada 60 m, mucha arena y mucha agua por metro**	**2024**
Intermedio	911	La misma idea a menor escala: 2.256 m, 29 etapas cada 76 m	2020
Arena importada	132	Se distingue por el abastecimiento, no por la geometría: 90% de arena importada	2016
Baja intensidad	84	Pozos fracturados muy espaciado: 7 etapas cada 133 m, diez veces menos agua por metro	2017

El dato que hace el remate: el algoritmo **nunca vio el año** en que se fracturó cada pozo. Y sin embargo las cuatro familias salen ordenadas en el tiempo: 2024, 2020, 2016, 2017. Sin que nadie se lo pidiera, reconstruyó **la historia del diseño de pozos en Vaca Muerta** — la misma que nosotros habíamos descrito a mano en la primera parte del trabajo, mirando gráficos uno por uno.

Y además producen distinto

Acá está la prueba de que esto no es un ejercicio decorativo. **La producción no entró al ajuste**: el algoritmo armó las familias sin saber cuánto produjo ningún pozo. Entonces mirarla después es una verificación honesta.

Familia	Pozos medidos	Producción típica (m^3)
Intensivo moderno	**1.078**	**36.760**
Intermedio	716	26.422
Arena importada	92	15.638
Baja intensidad	31	3.311

Un factor de **once** entre la primera familia y la última, y en el mismo orden que la intensidad del diseño. Dicho simple: **el algoritmo agrupó por cómo se fractura y, sin proponérselo, agrupó también por cuánto se produce**.

La advertencia de siempre, y hay que decirla antes de que la pregunten: las familias están pegadas a la época, y entre 2015 y 2024 no cambió sólo el diseño. Esto *describe* muy bien lo que pasó; no prueba qué lo causó.

Lo que apareció al comprimir el espacio

La cursada enseñó también a **reducir dimensiones**: quedarse con menos variables que resuman lo mismo. Lo aplicamos, y dio el resultado más fino de esta parte.

Dimensiones que dejamos	Información retenida	¿Salen las mismas familias?
4 de 5	99,4%	Sí (0,998)
3 de 5	**94,7%**	**Sí (0,958)**
2 de 5	78,0%	**No (0,374)**

Entre tres y dos dimensiones el agrupamiento **se rompe**. Y la dimensión que se pierde en ese paso es, casi exclusivamente, la arena importada. Dicho simple: **la familia de arena importada vive en esa dimensión y sin ella se disuelve**.

> **La lección, que es general:** esa dimensión aporta apenas el 17% de la información total. Si hubiéramos descartado dimensiones por su peso —que es lo que se hace casi siempre— habríamos borrado justamente el grupo más distintivo. **Que algo explique poca variabilidad no significa que importe poco.**

El cruce que vale la pena contar

> La **arena importada** fue la variable que los modelos de las partes anteriores descartaron por inútil: +79 m³ en uno e importancia **0,0000 exacta** en el otro. En esta parte **define una familia entera**, de 132 pozos.
>
> No es una contradicción, y explicarlo bien deja muy buena impresión: son preguntas distintas. **Predecir cuánto va a producir un pozo y describir cómo fue diseñado no son lo mismo**, y una variable puede ser irrelevante para la primera y central para la segunda. Si hay una sola frase para llevarse de la cuarta parte, es ésta.

11. La quinta parte: el modelo, en producción

Un modelo que vive dentro de un cuaderno no lo puede usar nadie más que quien lo escribió. La última parte del trabajo fue sacarlo de ahí: el modelo entrenado se guarda en un archivo y se sirve como una **API**, un programa que escucha pedidos por internet y responde.

Está desplegada y funcionando: `entregafinal-data-science.onrender.com/docs`

Corre en la capa gratuita de Render, que **duerme el servicio tras quince minutos sin uso**: la primera petición puede tardar hasta un minuto en despertarlo. Abrir la página diez minutos antes de presentar y dejarla abierta.

La analogía. Es la diferencia entre tener una receta escrita en un cuaderno y tener un horno al que le pasás los ingredientes y te devuelve el pan. Cualquiera puede usar el horno sin saber leer la receta ni tener la cocina.

Qué hace

Recibe **las decisiones de diseño tal como se declaran** —metros de rama, cantidad de etapas, toneladas de arena, metros cúbicos de agua, presión, potencia, días de operación y operadora— y devuelve tres cosas:

- **La estimación** en metros cúbicos a doce meses.
- **Un rango.** Cada uno de los 600 árboles del bosque vota un número; mostramos el desacuerdo entre ellos. No es un intervalo de confianza estadístico, pero es más honesto que un número solo.
- **Las variables de intensidad** que calculó, para que se vea exactamente qué entró al modelo.

Y avisa si la **operadora es desconocida**: una que el modelo no vio al entrenar no rompe nada, pero la estimación pierde el aporte de esa variable y conviene saberlo.

La decisión de diseño que conviene poder explicar

> Las cinco fórmulas que construyen las variables de intensidad están escritas **una sola vez**, en un archivo que importan tanto el entrenamiento como la API.
>
> Podrían haberse escrito dos veces, una en cada lado. El problema es que el día que alguien corrige una, la otra queda vieja, y el modelo empieza a recibir en producción números distintos de los que vio al entrenar. Es un error silencioso: nada falla, solo que las predicciones dejan de valer. **Compartir el código es la forma de que eso no pueda pasar.**

Lo que responde

Las dos palancas del modelo se pueden mostrar en vivo, pidiéndole estimaciones y cambiando una sola cosa:

Alargar la rama (arena, agua y etapas en proporción)	Estimación
2.000 m, 34 etapas	29.224 m³
2.800 m, 48 etapas	38.506 m³
3.600 m, 62 etapas	**49.903 m³**

Apretar las etapas (todo lo demás igual)	Estimación
28 etapas, una cada 100 m	33.365 m³
40 etapas, una cada 70 m	36.871 m³
56 etapas, una cada 50 m	38.067 m³

La primera tabla sube con fuerza y la segunda **se aplana**. Es el mismo resultado de los coeficientes de la sección 8, convertido en algo que se puede mostrar en pantalla.

> **Para la demostración en vivo.** Tener el servicio **ya levantado y la pestaña abierta antes de empezar**, nunca arrancarlo delante de todos. Abrir `/docs`, que es la documentación interactiva que se genera sola, apretar «Try it out», mandar el pozo de ejemplo, y después subir la longitud de rama y volver a ejecutar para que el número suba a la vista. Los valores de las tablas de arriba son los reales: si la conexión falla, la diapositiva sostiene el argumento sola.

12. Las preguntas que nos pueden hacer

"Un 26% es poquísimo. ¿No les salió mal el modelo?"

Es poco como número absoluto y es honesto como resultado. Tres cosas: le gana a la referencia por un **25% menos de error**, no por poco; probamos cuatro modelos y 180 ajustes de parámetros y ninguno lo mueve, así que **el techo está en los datos, no en el modelo**; y lo que falta es la geología, que no está publicada. Un modelo que sólo ve el diseño no puede explicar la roca. Lo que sí podíamos elegir era informar el 26% que se sostiene en lugar del 52% que se cae.

"¿Por qué no probaron algo más potente, una red neuronal?"

Porque la evidencia dice que no hay nada que ganar por ese lado. Un modelo lineal simple da 0,240 y el mejor de árboles 0,263: están casi empatados, lo que indica que la señal que hay en estas variables es sencilla. Y las 180 combinaciones de parámetros que probamos mejoran la validación un 2,9% y **no mejoran la prueba**: 10.659 m³ contra los 10.596 del modelo ajustado a mano, una diferencia más chica que la que produce cambiar la semilla aleatoria. Con más capacidad el riesgo es el opuesto: el modelo de árboles ya aprende de memoria (0,714 en lo que estudió contra 0,263 en lo nuevo).

"¿Por qué partieron los datos por año y no al azar?"

Porque el uso real del modelo es estimar los pozos del año que viene, y porque el diseño cambia año a año. Partir al azar le deja ver al modelo pozos del mismo período con el que después se lo evalúa, y eso infla el resultado al doble. Está medido en el notebook, con las dos particiones sobre el mismo modelo.

"¿Cómo saben que no se les filtró información de la prueba?"

Todo el preprocesamiento —rellenar faltantes, escalar, codificar la operadora— está dentro de un `Pipeline` que se ajusta **sólo con los pozos de aprendizaje**. El corte entre pozos "altos" y "bajos" de la clasificación se calcula con el valor típico de esos mismos pozos, no del total. Y los 619 pozos de prueba se usan una sola vez, al final.

"Incluyen la operadora como variable. ¿No es hacer trampa?"

Es el único proxy de geología que tenemos: cada empresa trabaja en áreas de distinta calidad de roca. Sacarla no haría al modelo más honesto, lo haría más ciego, y además esconde el hallazgo más importante: que la geología pesa tanto como la mejor variable de diseño. Lo que sí hacemos es decirlo explícitamente en los tres lugares donde aparece: **eso no mide a la empresa, mide al área**, y no se puede usar para rankear operadoras.

"¿Probaron agregar el año de fractura? Debería mejorar."

Sí, y mejora: el R^2 sube de 0,263 a 0,285. **Lo descartamos igual.** Cuando movemos el año de corte, la mejora cambia de signo (+0,047 en un corte, −0,043 en otro), y el mecanismo que la produce es extrapolar a un año que el modelo nunca vio, que no es confiable. Preferimos el modelo que explica menos por razones que se sostienen. Es la decisión de la que estamos más conformes.

"¿Y los valores extremos? ¿No habría que sacarlos?"

Distinguimos dos cosas. Los valores **imposibles** —presión cero, 3 metros de rama— los corregimos, porque son errores de carga. Los pozos **excepcionalmente buenos o malos** no: son pozos reales y sacarlos sería maquillar el resultado. Lo que hicimos es medir dónde falla el modelo: le sobreestima 13.053 m³ al quintil menos productivo y le subestima 11.461 al más productivo. En el rango central el error baja a unos 5.700-7.100 m³. Dicho claro: **sirve para un pozo típico y no sirve para anticipar el pozo excepcional ni el fracaso**.

"Se quedaron con 1.917 pozos de 4.890 filas. ¿No tiraron demasiado?"

No es descarte, es definición del alcance, y cada paso está justificado: el 42% eran pozos verticales, que son otra tecnología con una escala cien veces menor; 191 pozos tienen el gas como objetivo y son otro problema; y a los pozos que no cumplieron doce meses no se les puede medir la variable que queremos predecir. Analizarlos todos juntos no describiría bien a ninguno.

“¿Esto sirve para algo en la práctica?”

Sirve para tres cosas concretas. Ordena las decisiones de diseño por cuánto rinden, y dice que la rama es la que manda. Da un resultado negativo accionable: la arena importada no se paga. Y deja una advertencia de método que vale para cualquier modelo que se compre o se venda: **exigir que se lo haya evaluado con datos posteriores a los del entrenamiento**.

“Si alargo la rama, ¿produzco más? ¿Es causal?”

No podemos afirmarlo. Son **asociaciones**: sólo existen los pozos que efectivamente se perforaron, y no hay un pozo gemelo con otro diseño con el que comparar. Lo que sí se puede decir es que la dirección de todos los efectos es coherente con la física del problema, lo que da confianza de que el modelo está captando algo real y no ruido.

“Si no hay respuesta correcta, ¿cómo saben que no inventaron esos grupos?”

Por dos verificaciones independientes. La primera: el algoritmo **reconstruyó la cronología del diseño sin ver una sola fecha**; si los grupos fueran arbitrarios, las familias estarían mezcladas en el tiempo y no lo están. La segunda: **la producción quedó fuera del ajuste** y aun así las familias la ordenan, de 36.760 m^3 a 3.311 m^3. Un corte arbitrario del espacio no haría ninguna de las dos cosas.

“¿Y por qué cuatro familias? ¿No es un número elegido a dedo?”

Es una decisión nuestra y está argumentada en el notebook, que es lo que corresponde cuando no hay respuesta correcta. Probamos los cuatro índices que se usan para esto y **ninguno elige el mismo número**: dos votan 2 y uno vota 6. Nos quedamos con 4 por tres razones: es estable —distintos arranques del algoritmo dan exactamente los mismos grupos—, ninguna familia queda tan chica como para ser anecdótica, y es el número más alto en el que cada grupo sigue correspondiendo a una forma reconocible de completar un pozo. Con cinco, el grupo grande se parte en dos mitades con el mismo perfil.

“¿Hubo algo que les saliera mal en esta parte?”

Sí, y es la parte más instructiva. En el primer intento el algoritmo dedicó **un grupo entero a tres pozos** —dos de ellos fracturados en una sola etapa sobre más de mil metros— y la métrica de calidad nos felicitó con un 0,62, que es un valor altísimo. Al corregirlo, la métrica **empeoró** a 0,40 y los grupos pasaron a tener cientos de pozos cada uno. Es la tercera vez en el proyecto que una métrica que mejora resulta ser una señal de alarma, no de éxito.

“¿Por qué el modelo que sirve la API no es el mismo que midieron?”

Porque son dos cosas distintas y conviene no mezclarlas. Para **medir** hay que entrenar con pozos viejos y evaluar con nuevos, que es la única forma honesta: de ahí salen el MAE de 10.596 m^3 y el R^2 de 0,263. Para **servir**, en cambio, no tiene sentido ignorar los 619 pozos más recientes, así que el modelo final se reentrena con los 1.917. El archivo de metadatos deja escritas las dos cosas, así nadie confunde el número que se midió con el modelo que responde.

“¿Cómo saben que la API hace lo mismo que el notebook?”

Por dos cosas. El script que entrena reconstruye todo desde los archivos originales y llega **exactamente a los mismos números**: MAE 10.596 y R^2 0,263, idénticos a los del cuaderno. Y el preprocesamiento no se reescribió: está dentro del mismo objeto `Pipeline` que se guarda entero en el archivo, así que la predicción en producción recorre el mismo camino que en el entrenamiento.

“Si el diseño de los pozos cambia año a año, ¿esta API no se va a quedar vieja?”

Sí, y es nuestra propia conclusión aplicada a nosotros mismos. El modelo está validado sobre pozos de 2024-2025; a medida que el diseño siga cambiando, va a ir perdiendo precisión. Por eso hay que **reentrenar y volver a medir con la partición temporal**, no asumir que sigue valiendo. Está escrito en el README y en la descripción de la propia API, no en una nota al pie.

“¿Cualquiera puede reproducir estos números?”

Sí, y es deliberado. Las versiones de todas las librerías están fijadas con `==` en `requirements.txt`, la semilla aleatoria está fija, y la fecha de corte sale del propio archivo en lugar de la fecha de hoy, así que el notebook da lo mismo si se corre dentro de un año. Los tres notebooks corren de principio a fin sin intervención.

13. Glosario de bolsillo

Palabra	En una línea
Modelo supervisado	Aprende de ejemplos que ya traen la respuesta, para después responder sobre casos nuevos.
Regresión / clasificación	Predecir un número (cuántos m^3) / predecir una categoría (bueno o malo).
Modelo de referencia	El "loro": predice siempre lo mismo sin mirar nada. La vara mínima que hay que superar.
MAE	Error promedio, en la misma unidad que lo que se predice. El nuestro: 10.596 m^3.
R^2	Qué parte de las diferencias entre pozos queda explicada. De 0 a 1. El nuestro: 0,263.
Sobreajuste	Andar bien en lo que se estudió y mal en lo nuevo. Se detecta comparando las dos cosas.
Validación cruzada	Repetir la evaluación varias veces con distintos recortes, para no depender de un sorteo con suerte.
Pipeline	Encadenar la preparación de los datos y el modelo en una sola pieza, para que la preparación nunca vea los datos de prueba.
Matriz de confusión	La tabla de aciertos y errores del clasificador, separados por tipo. Muestra que el nuestro detecta buenos pozos (90%) mucho mejor de lo que descarta malos (42%).
AUC	Si tomás un pozo bueno y uno malo al azar, la probabilidad de que el modelo los ordene bien. El nuestro: 0,744.
Importancia por permutación	Se desordena una variable a propósito y se mide cuánto empeora el modelo. Si no empeora, no la estaba usando.
Aprendizaje no supervisado	Buscar estructura en los datos sin tener la respuesta correcta. No se predice nada: se describe.
Clustering / K-Means	Agrupar cosas parecidas. K-Means arma los grupos buscando que cada punto quede cerca del centro del suyo.
Silueta	Mide qué tan bien separados están los grupos, de −1 a 1. Ojo: premia aislar unos pocos puntos raros.
PCA	Comprimir muchas variables en dos, para poder dibujar en un gráfico plano algo que vive en cinco dimensiones.
Reducción de dimensionalidad (SVD)	Resumir muchas variables en menos, quedándose con las direcciones donde los datos más se diferencian.
API	Un programa que escucha pedidos por internet y responde. Acá: le mandás el diseño de un pozo y te devuelve la estimación.
Endpoint	Cada dirección concreta de una API. La nuestra tiene cuatro; la que predice es `/predict`.

Serializar	Guardar un modelo ya entrenado en un archivo, para volver a usarlo sin reentrenarlo.

14. El orden sugerido para contarlo

1. **El problema** (sección 2): tres frases, con la esponja y la arena. Sin números.
2. **La pregunta**: cuánto va a producir un pozo sabiendo sólo cómo se lo diseñó.
3. **Los datos**: dos archivos públicos cruzados, 1.917 pozos para los modelos y 2.603 para el clustering, y por qué son ésos.
4. **El resultado**: 25% menos de error que la referencia, R^2 0,263, y qué significa y qué no.
5. **El hallazgo** (sección 7): temporal contra aleatorio, con la analogía del examen. Es el momento fuerte de la presentación.
6. **La traducción** (sección 8): qué cambiaría una operadora. La rama manda; la arena importada no se paga.
7. **Lo que el modelo no hace**: decirlo nosotros, no esperar la pregunta.
8. **El extra** (sección 9): clasificar es peor que predecir el número y cortar, y por qué.
9. **El cierre** (sección 10): las cuatro familias de diseño, y que el algoritmo reconstruyó la cronología sin ver una fecha. Es lo que mejor funciona para terminar, porque se entiende sin saber qué es un R^2.
10. **La demostración** (sección 11): el modelo funcionando. Subir la longitud de rama y que el número suba delante de todos.

> **Un consejo sobre el tono.** La parte más fuerte del trabajo no es el R^2: es que en **tres** lugares distintos **elegimos el resultado peor porque era el correcto** —la partición temporal en lugar de la aleatoria, descartar el año de fractura aunque mejoraba la métrica, y acotar los valores extremos aunque la silueta cayera de 0,62 a 0,40—. Eso es lo que conviene poner adelante, porque es lo que no se consigue probando más modelos.
