PROYECTO FINAL · CIENCIA DE DATOS · ENERGIA DIGITAL 2026

DISEÑO DE COMPLETACIÓN Y PRODUCTIVIDAD DE POZOS EN VACA MUERTA

Cuánto de la producción de un pozo se explica por cómo se lo diseñó. Regresión, clasificación y clustering sobre 1.917 pozos de datos abiertos.

INTEGRANTES: CAROLINA BAILÓN · MARTÍN GERBALDO · FRANCO MALACALZA

DATOS PÚBLICOS DE LA SECRETARÍA DE ENERGÍA DE LA NACIÓN

CONTENIDO

LAS DIEZ SECCIONES

1. Objetivo del proyecto
2. Hipótesis
3. Metodología y datos
4. Limpieza y preparación
5. Cómo validamos
6. Agrupamiento con K-Means
7. Modelo predictivo: Random Forest
8. Predicción contra producción real
9. Conclusiones
10. Propuesta: el modelo en producción

1 · CAROLINA

OBJETIVO DEL PROYECTO

EL CONTEXTO

El petróleo está atrapado en la roca. Se perfora un tramo horizontal de kilómetros y se lo agrieta bombeando agua con arena, en decenas de etapas.

EL PROBLEMA

Ese **diseño de completación** concentra buena parte del costo del pozo y se define **antes** de saber cuánto va a producir. No tiene vuelta atrás.

NOS PROPUSIMOS

- **Estimar** la producción de los primeros doce meses a partir del diseño.
- **Identificar** qué decisiones mueven la producción y cuáles no se pagan.
- **Agrupar** los pozos en familias de diseño.
- **Dejarlo usable**: un servicio al que se le consulta un diseño y responde.

La pregunta, en una línea: ¿cuánto va a producir un pozo sabiendo sólo cómo se lo diseñó?

2 · CAROLINA

HIPÓTESIS

El diseño de completación explica **una parte real pero minoritaria** de la producción de un pozo: suficiente para **ordenar decisiones**, insuficiente para dictaminar sobre un pozo individual.

QUÉ ESPERÁBAMOS ENCONTRAR

Que la **intensidad por metro** —arena y agua divididas por la rama— explicara más que las cantidades absolutas.

Y QUÉ SOSPECHÁBAMOS

Que una parte de lo que parece diseño fuera en realidad **geología**, que no está en los datos abiertos.

CÓMO SE PONE A PRUEBA

Comparando el modelo contra una **referencia**: predecir siempre la producción típica. Si no le gana, el diseño no explica nada.

UNA HIPÓTESIS QUE SE PUEDE REFUTAR: ÉSA FUE LA CONDICIÓN

3 · CAROLINA

METODOLOGÍA Y DATOS

3
archivos abiertos de la Secretaría de Energía, cruzados por el id del pozo

1.917
pozos de petróleo con doce meses completos de producción medida

12
meses: los m³ de petróleo acumulados que el modelo estima

Archivo	Qué aporta
fractura_adjunto_iv.csv	El diseño declarado de cada fractura: rama, etapas, arena, agua, presión, potencia
produccion_por_pozo.csv	La producción mes a mes, de donde sale la variable objetivo
pozos_ubicacion.csv	Coordenadas y formación productiva, para el análisis exploratorio

PYTHON · PANDAS · SCIKIT-LEARN · FASTAPI · TODO REPRODUCIBLE DESDE EL REPOSITORIO

4 · MARTÍN

LIMPIEZA Y PREPARACIÓN

CEROS QUE NO ERAN CEROS

En presión, potencia y agua había ceros que marcaban «no informado». Los tratamos como faltantes y los imputamos con la **mediana de su formación geológica**, no la global.

VARIABLES CONSTRUIDAS

Las cinco de **intensidad**: arena por metro, agua por metro, espaciamiento entre etapas, ratio agua-arena y ratio de arena importada.

QUÉ DEJAMOS AFUERA

Los pozos cuyo objetivo es el **gas**: medirlos en m³ de petróleo sería la métrica equivocada. Y los que no llegan a doce meses.

Todo el preprocesamiento viaja dentro del mismo **Pipeline** de scikit-learn que se serializa, así que entrenamiento y producción recorren exactamente el mismo camino.

ONE-HOT PARA LA OPERADORA · IMPUTACIÓN POR MEDIANA · EXTREMOS DEL 1% REVISADOS

5 · MARTÍN

CÓMO VALIDAMOS: EL HALLAZGO

PARTICIÓN AL AZAR · 80/20

R^2 0,52

Entrena con pozos de 2024 y se lo evalúa con vecinos suyos, del mismo año y la misma zona.

PARTICIÓN TEMPORAL

R^2 0,26

1.298 pozos hasta 2023 para entrenar, 619 de 2024-2025 para evaluar. **Es el que informamos.**

No cambió el modelo ni los datos: cambió la pregunta. Como se va a usar sobre pozos nuevos, **el número honesto es el peor**.

VALIDACIÓN CRUZADA CON TIMESERIESSPLIT · 180 COMBINACIONES DE HIPERPARÁMETROS PROBADAS

6 · MARTÍN

AGRUPAMIENTO CON K-MEANS

CONVENCIONAL

Rama corta, poca arena por metro. Los pozos más viejos de la cuenca.

INTENSIVO

Rama larga y mucha arena por metro. El diseño que se impuso.

ARENA IMPORTADA

Se distingue por el origen de la arena, no por la geometría.

ALTO VOLUMEN

Mucha agua por tonelada de arena: fluido más liviano.

CÓMO ELEGIMOS K = 4

Codo, silueta y Calinski-Harabasz sobre 2.603 pozos —686 más que en regresión, porque el clustering no necesita la variable objetivo—. **Silueta 0,40.**

LO QUE MÁS NOS SORPRENDIÓ

El algoritmo **reconstruyó la cronología** de la cuenca sin haber visto una sola fecha: las familias se ordenan por época.

7 · MARTÍN

MODELO PREDICTIVO: RANDOM FOREST

10.596
MAE en m^3: el error absoluto medio sobre pozos que el modelo nunca vio

25%
mejor que la referencia de predecir siempre la producción típica

0,263
R^2: el modelo explica el 26% de la variabilidad de la producción

POR QUÉ UN BOSQUE

600 árboles, mínimo 8 muestras por hoja. Son datos tabulares y 1.917 filas: con ese tamaño una red neuronal no tiene ventaja. Le ganó a la regresión lineal y al árbol solo.

QUÉ PESA MÁS

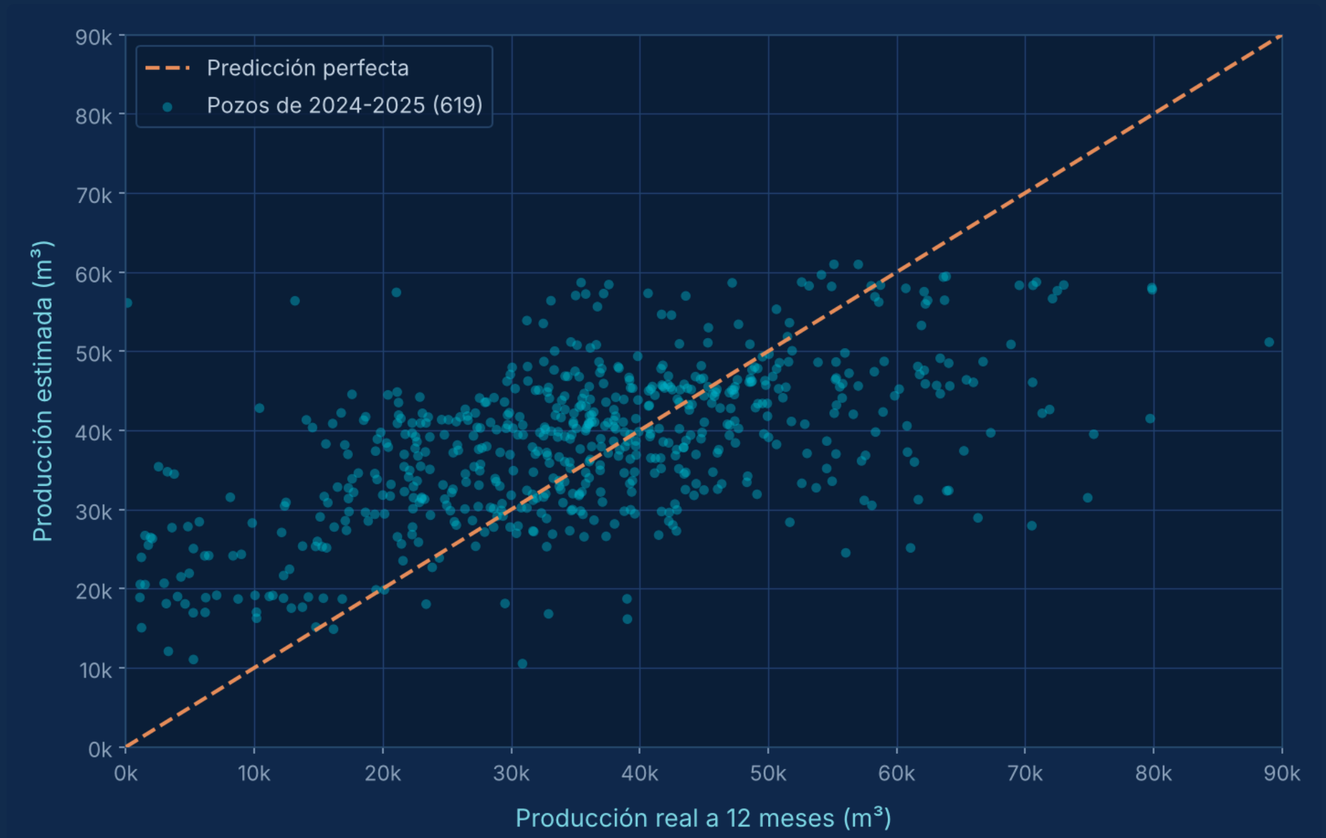
La **longitud de rama** y la **intensidad por metro**. La arena importada es la variable menos importante: **no se paga**.

Cuidado con la operadora: pesa tanto como la mejor variable de diseño, pero mide la calidad del área que tiene en concesión, no su habilidad. No sirve para comparar empresas.

SON ASOCIACIONES, NO CAUSAS: SÓLO EXISTEN LOS POZOS QUE EFECTIVAMENTE SE PERFORARON

8 · FRANCO

PREDICCIÓN CONTRA PRODUCCIÓN REAL



LA NUBE SE ACHATA

El modelo **comprime hacia el centro**: a los pozos que produjeron 57.000 m³ les estima 49.000, y a los que produjeron 15.000 les estima 26.000.

QUÉ SIGNIFICA

No anticipa **ni el pozo excepcional ni el fracaso**, que son los dos casos donde más dinero hay en juego. Sí ordena bien el grueso.

619 POZOS DE 2024-2025 · NINGUNO VISTO DURANTE EL ENTRENAMIENTO

9 · FRANCO

CONCLUSIONES

Elegimos	En vez de	Por qué
Partición temporal, R^2 0,26	Al azar, 0,52	El uso real es con pozos nuevos
Sin el año de fractura, 0,263	Con el año, 0,285	La mejora cambiaba de signo según el corte
Extremos acotados, silueta 0,40	Sin acotar, 0,62	Ese 0,62 premiaba aislar tres pozos

LA HIPÓTESIS SE CONFIRMA

El diseño explica el **26%**: una parte real y minoritaria. Sirve para **ordenar diseños y comparar carteras**, no para dictaminar sobre un pozo.

Y EL TECHO ES DE LOS DATOS

Lo que falta no es un algoritmo mejor: es la **geología**, que no está en los datos abiertos.

TRES VECES ELEGIMOS EL NÚMERO PEOR PORQUE ERA EL CORRECTO

PROPUESTA: EL MODELO EN PRODUCCIÓN

LO QUE ENTREGAMOS

El modelo no se queda en el cuaderno: se sirve como una **API desplegada**, con un panel donde se mueve el diseño y la estimación se actualiza sola.

PARA QUÉ SE USARÍA

Comparar diseños alternativos antes de fracturar y evaluar una **cartera** de pozos planificados contra lo esperable.

QUÉ SIGUE

Incorporar **geología**, que es el techo actual; recalibrar el rango; y reentrenar a medida que el diseño de la cuenca siga cambiando.

Y avisa dónde se queda sin datos: si se le pide un pozo de 8.000 m responde igual, pero advierte que **el más largo que vio mide 4.965** y que de ahí en más devuelve siempre lo mismo.

`entregafinal-data-science.onrender.com/demo` · el panel · `/docs` · la API

MUCHAS GRACIAS

Carolina Bailón · Martín Gerbaldo · Franco Malacalza

github.com/FrancoMalacalza01/entrega-final-data-science

entregafinal-data-science.onrender.com/demo